

Trabalho 1 – Segmentação de Texturas

Aluno: Bruno Vila Lobus Strapasson

<https://github.com/BrunoVLStrapasson/Vis-o-Computacional>

Objetivo

O trabalho tem como objetivo desenvolver uma solução clássica de processamento de imagens para segmentar regiões de acordo com suas características de textura. A solução utiliza imagens em tons de cinza, um banco de filtros, três escalas de processamento, extração de características por regiões e posterior agrupamento das regiões semelhantes.

Conjunto de imagens

Foi selecionado um conjunto de 32 imagens de texturas, superfícies como pisos, concreto, pedras, tijolos, argamassa e revestimentos. As imagens estão em JPG e possuem 512×512.

Pré-processamento

As imagens são carregadas com OpenCV e convertidas para escala de cinza. A primeira escala mantém a resolução original de 512×512. Para a segunda escala, aplica-se suavização gaussiana e redução para 256×256. Para a terceira, uma nova suavização é aplicada e a imagem é reduzida para 128×128.

Banco de filtros

Foi implementado um banco com oito filtros 0°, 45°, 90° e 135°, Laplaciano, laplaciano da gaussiana, diferença de gaussianas e um filtro circular. Os filtros angulares permitem analisar padrões direcionais, enquanto os demais complementam a análise com respostas a bordas, detalhes, variações de escala e estruturas radiais.

Divisão em regiões e extração de características

Cada imagem é representada por uma grade de 8×8 regiões, totalizando 64 regiões. Em cada escala, as regiões correspondentes são analisadas com os oito filtros. A característica de uma região para um determinado filtro é calculada pela média dos valores absolutos da resposta do filtro na janela. Assim, cada região recebe 8 características por escala. Como existem 8 filtros e 3 escalas, cada região é descrita por um vetor de 24 dimensões.

Organização dos dados

Para cada uma das 32 imagens são extraídos 64 vetores. Portanto, o conjunto completo possui $32 \times 64 = 2048$ regiões. A matriz final de características possui dimensão 2048×24.

Foi implementada a gravação dos vetores em arquivos CSV, ele é utilizado como forma de armazenar e inspecionar os vetores. Cada linha representa uma região e contém a identificação da imagem, da região e suas 24 características. Também permite testar a etapa de agrupamento sem recalculando todo o processamento das imagens.

Normalização

Foi implementada a normalização Z-score das 24 características. Para cada dimensão, calcula-se a média e o desvio-padrão considerando as 2048 regiões e aplica-se $z = (x - \text{média}) / \text{desvio-padrão}$. Essa etapa evita que características com valores numericamente maiores dominem a comparação por distância Euclidiana.

Resultados obtidos

Extração de Características e Matriz Global

O processamento do conjunto de 32 imagens foi executado. Cada imagem de 512×512 foi subdividida em uma grade de 8×8 regiões, gerando 64 regiões por imagem. Com a aplicação do banco de 8 filtros em 3 escalas distintas, cada região foi descrita por um vetor de 24 dimensões.

Normalização Z-Score

Como os valores médios de resposta dos filtros possuem magnitudes variadas, aplicou-se a normalização Z-score em toda a matriz de dados. Essa etapa recalcula a média e o desvio-padrão de cada uma das colunas, garantindo que nenhuma característica exerça influência desproporcional sobre o cálculo da distância Euclidiana durante o agrupamento. Os dados normalizados foram salvos em um CSV.

Segmentação por Agrupamento K-Means e Visualização

Para avaliar a eficácia da extração de texturas, o algoritmo K-Means foi executado sobre os dados normalizados considerando 4 clusters representando quatro padrões predominantes ou fronteiras estruturais. A partir dos rótulos gerados, as imagens foram reconstruídas com sobreposição de cores translúcidas sobre as imagens originais.


Discriminação de Superfícies

O algoritmo demonstrou boa capacidade de separar texturas visualmente distintas como superfícies granulares densas versus superfícies estriadas ou planas, atribuindo cores diferentes a cada uma delas.


Quanto a detecção de Bordas e Descontinuidades Regiões de transição acentuada, fissuras ou relevos profundos, eles alteram expressivamente a resposta de alta frequência dos filtros como o Laplaciano e os filtros circulares, fazendo com que o K-Means isole essas áreas em clusters próprios.

Comportamento nas Fronteiras


Observou-se que janelas situadas exatamente na linha de transição entre duas texturas distintas podem sofrer efeito de borda, gerando valores intermediários que resultam em classificações pontuais isoladas um comportamento esperado.




Cinza Original




Filtro Laplaciano




Resultado



Cinza Original



Filtro Circular



Resultado